ROBOTSKO ZAZNAVANJE • 3D-GEOMETRIJA • RGB-D PODATKI

Od sintetičnega oblaka točk do realnih RGB-D meritev: PCA in RANSAC

Matematična izpeljava, implementacija v C++20 in eksperimentalna validacija

Razširjeno raziskovalno-tehnično poročilo | 13. november 2026 | projekt `mapping_PCA`

Povzetek. Predstavljeno je lastno programsko ogrodje za ocenjevanje ravnin in geometrijsko segmentacijo tridimenzionalnih oblakov točk. Osnova je analiza glavnih komponent (PCA), ki prek težišča, kovariančne matrike in lastnega razcepa določi ravnino z najmanjšimi kvadratnimi pravokotnimi odmiki. Ker globalni PCA ni odporen na točke drugih objektov, je dodana metoda RANSAC, ki iz naključnih trojic točk išče dominantno ravnino in končni model izboljša s PCA. Metodi sta ovrednoteni na sintetični sceni s 40.401 točkami ravnine in 7.921 točkami kocke ter nato uporabljeni na realnem globinskem posnetku kamere Intel RealSense D455. Iz realne slike ločljivosti 848×480 je pridobljen oblak 347.474 veljavnih 3D-točk; RANSAC izbere 339.796 inlierjev in doseže RMSE njihovega prileganja približno 2,20 mm. Razvita je tudi transformacija v koordinatni sistem zaznane ravnine in prikaz višinske karte. Poudarjene so omejitve nenatančno znanih parametrov kamere in manjkajočih globinskih meritev.

Ključne besede: PCA, RANSAC, 3D-oblak točk, kovariančna matrika, geometrijska segmentacija, Intel RealSense D455, C++20, Eigen, OpenCV, višinska karta.

1 Uvod in raziskovalni cilj

Rekonstrukcija tridimenzionalne geometrije je temeljni gradnik robotskega zaznavanja. Iz globinskih meritev želimo izluščiti stabilne geometrijske površine, ugotoviti, katere točke pripadajo posamezni površini, in podatke predstaviti v smiselno izbranem koordinatnem sistemu. V tem delu ne ocenjujemo trajektorije kamere in ne izvajamo zanke zapiranja poti; obravnavamo *rekonstrukcijo enega pogleda, prileganje ravnine in segmentacijo* kot preverljivo osnovo za kasnejše kartiranje.

Razvoj je potekal v treh fazah. Prvotna študija je obravnavala PCA na eni sintetični ravnini in statistiko šuma. Nadgradnja je dodala kocko, s čimer se je izkazala omejitev globalne PCA-ocene, ter vpeljala RANSAC in ponovno oceno ravnine iz inlierjev. Zadnja faza je pretvorila realno 16-bitno globinsko sliko D455 v 3D-oblak in na njem izvedla *iste lastne funkcije* za prileganje in segmentacijo.

Osrednje vprašanje: kako z lastno C++-implementacijo iz šumnih 3D-meritev robustno oceniti dominantno ravnino, določiti pripadajoče točke ter iz njihovih koordinat izračunati višino ostalih meritev glede na ravnino?

2 Osnove geometrije in linearne algebre

2.1 Točka, vektor in skalarni produkt

Točko v prostoru označimo z $\boldsymbol{p} = [x, y, z]^T$. Razlika dveh točk, $\boldsymbol{AB} = \boldsymbol{p}_B - \boldsymbol{p}_A$, je vektor premika od točke A do točke B. Na primer, iz $A = (1, 1, 0)$ in $B = (3, 1, 0)$ dobimo $\boldsymbol{AB} = (2, 0, 0)$. Smer tega vektorja ne pove, kje točki ležita absolutno, temveč kako pridemo iz prve do druge.

Dolžina vektorja je $\|\boldsymbol{v}\| = \sqrt{v_x^2 + v_y^2 + v_z^2}$. Deljenje z dolžino da enotski vektor $\hat{\boldsymbol{v}} = \boldsymbol{v}/\|\boldsymbol{v}\|$, ki opisuje smer brez vpliva velikosti. Skalarni produkt $\boldsymbol{a}^T\boldsymbol{b} = a_x b_x + a_y b_y + a_z b_z$ pri enotskih vektorjih meri kosinus kota med smerema. Prav zato bomo z njim izračunavali razdaljo do ravnine in kotno napako ocenjene normale.

2.2 Vektorski produkt in enačba ravnine

Vektorski produkt $\boldsymbol{a} \times \boldsymbol{b}$ je pravokoten na oba vhodna vektorja. Če tri *nekolinearne* točke določajo ravnino, lahko dobimo njeno normalo kot

$$\boldsymbol{v}_1 = \boldsymbol{p}_B - \boldsymbol{p}_A, \quad \boldsymbol{v}_2 = \boldsymbol{p}_C - \boldsymbol{p}_A, \qquad \boldsymbol{n} = \frac{\boldsymbol{v}_1 \times \boldsymbol{v}_2}{\|\boldsymbol{v}_1 \times \boldsymbol{v}_2\|}. \tag{1}$$

Ravnino opišemo z $\boldsymbol{n}^T\boldsymbol{p} + d = 0$, pri čemer je $\|\boldsymbol{n}\| = 1$. Parameter $d = -\boldsymbol{n}^T\boldsymbol{p}_A$ postavi ravnino skozi izbrano točko. Za poljubno točko $\boldsymbol{p}$ je $e = \boldsymbol{n}^T\boldsymbol{p} + d$ *predznačena pravokotna razdalja*; njena absolutna vrednost je geometrijska razdalja. Na primer, za $z = 0$ je $\boldsymbol{n} = (0, 0, 1)$ in točka $(1, 1, 0{,}02)$ leži 20 mm nad ravnino.

3 Sintetični referenčni oblak in merilni model

3.1 Mreža točk, rotacija in translacija

Za sintetično ravnino se uporabi mreža

$$\boldsymbol{p}_{ij}^{(0)} = \begin{bmatrix} i\Delta & j\Delta & 0 \end{bmatrix}^T, \quad 0 \le i, j \le N, \qquad M = (N+1)^2. \tag{2}$$

Trenutna konfiguracija ima $\Delta = 0{,}01$ m in $N = 200$, torej stranico 2 m in $M = 40\,401$ točk. Z rotacijama $\alpha = 6{,}1^\circ$ okoli osi X ter $\beta = 12{,}3^\circ$ okoli osi Y in s translacijo $\boldsymbol{t} = (0{,}02, 0{,}13, 0{,}07)^T$ m dobimo

$$R_x(\alpha) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos\alpha & -\sin\alpha \\ 0 & \sin\alpha & \cos\alpha \end{bmatrix}, \qquad R_y(\beta) = \begin{bmatrix} \cos\beta & 0 & \sin\beta \\ 0 & 1 & 0 \\ -\sin\beta & 0 & \cos\beta \end{bmatrix}, \tag{3}$$

$$\boldsymbol{p}_i^{\text{ref}} = R\boldsymbol{p}_i^{(0)} + \boldsymbol{t}, \qquad R = R_y(\beta)R_x(\alpha). \tag{4}$$

Pri takšnem zapisu najprej deluje R_x, nato R_y. Referenčna normala je znana: $\boldsymbol{n}_{\text{ref}} = R(0, 0, 1)^T$. Translacija normale ne spremeni.

Dodatno je ustvarjena kocka s stranico 0,4 m (korak 0,01 m). Funkcija `CubeGen()` generira zgornjo in stranske površine brez spodnje vrste točk ($k > 0$), skupaj 7.921 točk. Obe geometriji se transformirata z istima R in $\boldsymbol{t}$, zato je kocka del iste scene. Celoten oblak vsebuje 48.322 točk.

3.2 Gaussov šum in omejitve modela

Sintetičnim točkam dodamo neodvisni izotropni Gaussov šum:

$$\boldsymbol{p}_i^{\text{meas}} = \boldsymbol{p}_i^{\text{ref}} + \boldsymbol{\varepsilon}_i, \qquad \boldsymbol{\varepsilon}_i \sim \mathcal{N}(\boldsymbol{0}, \sigma^2 I_3). \tag{5}$$

Standardni odklon σ pove razpršenost napake vsake koordinate, ne največjega možnega odmika. Izotropni model je primeren za numerično analizo, vendar ne opisuje v celoti realne globinske kamere, kjer so napake odvisne tudi od razdalje, površine, osvetlitve in vpadnega kota.

Tabela 1. Parametri dveh trenutnih sintetičnih eksperimentov.

Parameter	PCA in Monte Carlo	Ravnina + kocka, RANSAC
Ravnina	2×2 m; 40.401 točk	2×2 m; 40.401 točk
Dodatni objekt	brez	kocka 0,4 m; 7.921 točk
Merilni šum	$\sigma = 0, 5, 10, 30, 50, 100, 200$ mm	$\sigma = 10$ mm
Ponovitve / poskusi	100 na σ (700 ocen PCA)	300 naključnih trojic
Prag inlierjev	ni uporabljen	$\tau = 30$ mm

4 Matematična izpeljava PCA

4.1 Težišče in centriranje

Izmerjeni oblak označimo z $\{\boldsymbol{p}_i\}_{i=1}^{M}$; indeks meas v nadaljevanju izpustimo. Njegovo težišče je aritmetično povprečje, centrirani vektorji pa odmiki posameznih točk od težišča:

$$\bar{\boldsymbol{p}} = \frac{1}{M}\sum_{i=1}^{M}\boldsymbol{p}_i, \qquad \boldsymbol{q}_i = \boldsymbol{p}_i - \bar{\boldsymbol{p}}, \qquad \sum_{i=1}^{M}\boldsymbol{q}_i = \boldsymbol{0}. \tag{6}$$

Centriranje je bistveno, ker želimo analizirati obliko in orientacijo oblaka, ne njegove absolutne lege. Če vse točke premaknemo za enak vektor, ostanejo centrirani odmiki nespremenjeni. Posledično bo tudi ocenjena normala translacijsko invariantna.

4.2 Kovariančna matrika in geometrijski pomen

Razpršenost točk opiše kovariančna matrika

$$C = \frac{1}{M}\sum_{i=1}^{M}\boldsymbol{q}_i\boldsymbol{q}_i^{T} = \begin{bmatrix} C_{xx} & C_{xy} & C_{xz} \\ C_{xy} & C_{yy} & C_{yz} \\ C_{xz} & C_{yz} & C_{zz} \end{bmatrix}. \tag{7}$$

Produkt $\boldsymbol{q}_i\boldsymbol{q}_i^{T}$ je *zunanji produkt*: iz vektorja velikosti 3×1 in njegove transponirane oblike 1×3 nastane matrika 3×3. Diagonalni členi predstavljajo variance posameznih koordinat, nediagonalni pa kovariance oziroma skupno linearno spreminjanje koordinat. Matrika C je simetrična in pozitivno semidefinitna, saj za poljuben vektor $\boldsymbol{u}$ velja

$$\boldsymbol{u}^{T}C\boldsymbol{u} = \frac{1}{M}\sum_{i=1}^{M}(\boldsymbol{u}^{T}\boldsymbol{q}_i)^2 \geq 0. \tag{8}$$

Izraz na desni je povprečna kvadratna projekcija centriranih točk v smeri $\boldsymbol{u}$. Kovariančna matrika torej omogoča merjenje razpršenosti v katerikoli prostorski smeri.

4.3 Lastni razcep in izbira normale

Ker je C simetrična, obstaja ortonormiran nabor lastnih vektorjev $\boldsymbol{v}_k$ z realnimi nenegativnimi lastnimi vrednostmi λ_k:

$$C\boldsymbol{v}_k = \lambda_k\boldsymbol{v}_k, \qquad C = V\Lambda V^{T}, \qquad 0 \leq \lambda_1 \leq \lambda_2 \leq \lambda_3. \tag{9}$$

Lastni vektor je smer, pripadajoča lastna vrednost pa varianca točk v tej smeri. Pri skoraj ravninski množici sta dve smeri razpršenosti znotraj ravnine izraziti, smer pravokotno nanjo pa ima najmanjšo varianco. Zato je ocena enotske normale

$$\boxed{\hat{\boldsymbol{n}} = \boldsymbol{v}_1, \qquad \|\hat{\boldsymbol{n}}\|_2 = 1.} \tag{10}$$

Predznak lastnega vektorja je poljuben: $\hat{\boldsymbol{n}}$ in $-\hat{\boldsymbol{n}}$ opisujeta isto neorientirano ravnino. PCA zato sama po sebi ne določa, na katero stran površine naj kaže normala.

4.4 Povezava z ortogonalnimi najmanjšimi kvadrati

Razlog, da PCA vrne najbolje prilegajočo se ravnino, je mogoče pokazati brez dodatnih predpostavk o Gaussovi porazdelitvi. Ravnino zapišemo kot $\boldsymbol{n}^{T}\boldsymbol{p} + d = 0$, kjer je $\|\boldsymbol{n}\|_2 = 1$. Ta pogoj zagotavlja, da je $e_i = \boldsymbol{n}^{T}\boldsymbol{p}_i + d$ predznačena *pravokotna razdalja* točke od ravnine. Iščemo minimum povprečja kvadratov teh razdalj:

$$\min_{\|\boldsymbol{n}\|_2=1,\; d} J(\boldsymbol{n}, d), \qquad J(\boldsymbol{n}, d) = \frac{1}{M}\sum_{i=1}^{M}(\boldsymbol{n}^{T}\boldsymbol{p}_i + d)^2. \tag{11}$$

Za dano normalo odvajamo kriterij po d in odvod izenačimo z nič. Dobimo $d = -\boldsymbol{n}^T\bar{\boldsymbol{p}}$, zato mora optimalna ravnina potekati skozi težišče. Če ta izraz vstavimo nazaj v (11), sledi

$$J(\boldsymbol{n}) = \frac{1}{M}\sum_{i=1}^{M}(\boldsymbol{n}^T\boldsymbol{q}_i)^2 = \boldsymbol{n}^T C\boldsymbol{n}. \tag{12}$$

Po Rayleigh–Ritzovem izreku doseže izraz $\boldsymbol{n}^T C\boldsymbol{n}$ pri enotskih vektorjih najmanjšo vrednost λ_1, in sicer v smeri $\boldsymbol{v}_1$ [2]. S tem dobimo končno oceno ravnine

$$\boxed{\hat{\boldsymbol{n}} = \boldsymbol{v}_1, \qquad \hat{d} = -\hat{\boldsymbol{n}}^T\bar{\boldsymbol{p}}, \qquad \hat{\boldsymbol{n}}^T\boldsymbol{p} + \hat{d} = 0.} \tag{13}$$

PCA je torej za eno ravnino in kriterij pravokotnih kvadratnih odmikov globalna rešitev *ortogonalnih najmanjših kvadratov*. Optimalnost velja za ta kriterij; ni pa jamstvo pravilne segmentacije pri osamelcih ali več različnih površinah.

5 RANSAC: robustno iskanje ravnine

5.1 Zakaj globalni PCA ni dovolj?

PCA minimizira kvadratne odmike *vseh* podanih točk od ene ravnine. To je ustrezno, če oblak pripada eni sami ploskvi. V sceni s kocko pa točke stranic in zgornje ploskve ne pripadajo tlom. Ker jih globalni PCA obravnava enakovredno talnim točkam, se težišče in kovarianca spremenita in ocena ravnine je lahko pristranska.

RANSAC (*Random Sample Consensus*) izbere model tako, da čim več meritev ustreza geometrijskemu kriteriju. Namesto minimizacije kvadratov vseh točk najprej išče največjo skladno podmnožico, imenovano *inlierji*. Točke zunaj te podmnožice so *outlierji*; same po sebi še niso nujno posamezni prepoznani objekti.

5.2 Kandidat iz treh naključnih točk

V iteraciji k izberemo tri različne indekse a, b, c. Točke dajo dva smerna vektorja

$$\boldsymbol{v}_1 = \boldsymbol{p}_b - \boldsymbol{p}_a, \quad \boldsymbol{v}_2 = \boldsymbol{p}_c - \boldsymbol{p}_a, \quad \tilde{\boldsymbol{n}}_k = \boldsymbol{v}_1 \times \boldsymbol{v}_2. \tag{14}$$

Če $\|\tilde{\boldsymbol{n}}_k\|$ skoraj izgine, so točke skoraj kolinearne in ravnine ni mogoče zanesljivo določiti; vzorec zavržemo. V nasprotnem primeru kandidat določa

$$\boldsymbol{n}_k = \frac{\tilde{\boldsymbol{n}}_k}{\|\tilde{\boldsymbol{n}}_k\|}, \qquad d_k = -\boldsymbol{n}_k^T\boldsymbol{p}_a. \tag{15}$$

Zakaj tri točke? Ker je to najmanjše število nekolinearnih točk, ki v 3D enolično določi ravnino. Za popolnoma točne meritve bi kandidat že ležal skozi vse tri točke; pri šumnih meritvah je to le približek.

5.3 Pripadnost točke ravnini in konsenz

Za vsak kandidat preverimo vse točke. Ker je normala enotska, je pravokotna razdalja $r_{ik} = |\boldsymbol{n}_k^T\boldsymbol{p}_i + d_k|$. Točka je inlier, če je razdalja manjša od praga τ:

$$\mathcal{I}_k = \left\{ i : \left|\boldsymbol{n}_k^T\boldsymbol{p}_i + d_k\right| < \tau \right\}, \qquad k^* = \arg\max_k |\mathcal{I}_k|. \tag{16}$$

RANSAC obdrži kandidata z največjim številom inlierjev. Prag je v metrih; premajhen prag izloči dobre, a zašumljene meritve, prevelik pa sprejme tudi točke drugih površin. Pri obravnavani sintetični sceni je $\tau = 30$ mm, pri realnih meritvah pa je bil uporabljen $\tau = 8$ mm.

5.4 Zakaj več ponovitev?

Naključna trojica lahko vsebuje točke kocke ali več različnih površin. Če je delež pravih inlierjev v celotni množici w, je ob neodvisnem naključnem vzorčenju približna verjetnost, da so vse tri izbrane točke inlierji, enaka w^3. Po K poskusih je verjetnost vsaj enega povsem pravilnega vzorca približno

$$P_{\text{uspeh}} = 1 - (1 - w^3)^K, \qquad K \geq \frac{\ln(1 - P_{\text{cilj}})}{\ln(1 - w^3)}. \tag{17}$$

Izraz velja pod predpostavko približno neodvisnih vzorcev in znanega deleža w; ne zagotavlja pravilne ocene modela pri degeneraciji, slabi izbiri praga ali več primerljivih ravninah. V implementaciji uporabljamo fiksno število poskusov: 300 na sintetični sceni oziroma 50 na realnem oblaku.

5.5 Kako se RANSAC in PCA povežeta

RANSAC izbere najboljšo množico inlierjev, vendar je njen model prvotno izračunan samo iz treh naključnih meritev. Zato je normalo smiselno ponovno oceniti iz *vseh* izbranih inlierjev z metodo PCA. V kodi se najprej iz teh točk izračunata težišče in kovariančna matrika, nato pa normalo poda lastni vektor najmanjše lastne vrednosti. Po izboljšanju se inlierji še enkrat preverijo z istim pragom.

$$\boxed{\text{RANSAC: izbor } \mathcal{I} \quad \longrightarrow \quad \text{PCA na } \{\boldsymbol{p}_i\}_{i\in\mathcal{I}} \quad \longrightarrow \quad (\hat{\boldsymbol{n}}, \hat{d}).} \tag{18}$$

Bistvo kombinacije: RANSAC je odgovoren za *robustno izbiro podatkov*, PCA pa za *natančno oceno ravnine iz izbranih podatkov*. Ta postopek je v literaturi znan tudi kot ponovno prileganje modela z inlierji.

Tabela 2. Primerjava uporabljenih algoritmov.

Lastnost	Globalna PCA	RANSAC + PCA
Vhodne točke	celoten oblak	celoten oblak; PCA le na inlierjih
Kriterij	najmanjši kvadratni odmiki	največ inlierjev znotraj praga
Občutljivost na kocko	velika, ker vpliva na kovarianco	praviloma manjša, če prevladuje ravnina
Naključnost	deterministična	odvisna od semena in ponovitev
Izhod	ena prilegajoča se ravnina	dominantna ravnina in indeksi inlierjev

6 Merila kakovosti in statistično vrednotenje

Orientacijo vrednotimo s kotom med referenčno in ocenjeno normalo. Ker sta smeri $\hat{\boldsymbol{n}}$ in $-\hat{\boldsymbol{n}}$ ekvivalentni, v skalarnem produktu uporabimo absolutno vrednost:

$$\theta = \frac{180}{\pi} \arccos\!\left(\text{clip}\left(\left|\boldsymbol{n}_{\text{ref}}^T \hat{\boldsymbol{n}}\right|, 0, 1\right)\right). \tag{19}$$

Kot θ je izražen v stopinjah. Operacija clip prepreči numerično napako funkcije arccos, če zaokroževanje povzroči vrednost nekoliko nad 1.

Prileganje ocenjene ravnine merimo s korenom povprečne kvadratne napake (RMSE) predznačenih pravokotnih odmikov:

$$\text{RMSE} = \sqrt{\frac{1}{M}\sum_{i=1}^{M} (\hat{\boldsymbol{n}}^T \boldsymbol{p}_i + \hat{d})^2} = \sqrt{\lambda_1}. \tag{20}$$

Zadnja enakost velja natančno za minimizacijski kriterij (11) in kovariančno matriko (7) z deljenjem z M. RMSE meri odstopanja *točk od ocenjene ravnine*, zato ga ne smemo enačiti z napako položaja same ravnine glede na referenco.

Napako težišča določimo z

$$e_c = \|\bar{\boldsymbol{p}}_{\text{meas}} - \bar{\boldsymbol{p}}_{\text{ref}}\|_2. \tag{21}$$

Pri neodvisnem izotropnem Gaussovem šumu ima vsaka koordinata napake težišča varianco σ^2/M. Ker je napaka e_c norma trirazsežnega normalnega vektorja, njena pričakovana vrednost znaša

$$\mathbb{E}[e_c] = 2\sqrt{\frac{2}{\pi}}\frac{\sigma}{\sqrt{M}}. \tag{22}$$

Pri prvotni konfiguraciji $M = 1681$ in $\sigma = 100\,\text{mm}$ dobimo $\mathbb{E}[e_c] \approx 3{,}89\,\text{mm}$; za gostejši oblak $M = 40401$ je pričakovana napaka težišča ob istem σ približno $0{,}794\,\text{mm}$, če veljajo predpostavke neodvisnega šuma. Teorija zato napoveduje bistveno manjšo napako težišča kot šum posamezne meritve.

Pomembna omejitev formule RMSE. Enakost RMSE $= \sqrt{\lambda_1}$ velja, ko se RMSE računa na *isti množici točk*, za katero je PCA določila optimalno ravnino. Pri RANSAC-u se konsenz po izboljšanju lahko spremeni; tam RMSE računamo neposredno na končnih inlierjih in enakosti z lastno vrednostjo prvotne PCA ni treba predpostaviti.

6.1 Monte Carlo metoda

Za vsako standardno deviacijo šuma σ se iz istih referenčnih točk generira $K = 100$ neodvisnih realizacij šuma in vsakič izvede PCA. Povprečje in vzorčni standardni odklon kotne napake sta

$$\bar{\theta} = \frac{1}{K}\sum_{k=1}^{K}\theta_k, \qquad s_\theta = \sqrt{\frac{1}{K-1}\sum_{k=1}^{K}(\theta_k - \bar{\theta})^2}. \tag{23}$$

Tako se loči rezultat posamezne naključne realizacije od stabilnega obnašanja metode. V novem projektu je preizkušenih sedem jakosti šuma, torej 700 PCA-ocen. V starejšem članku iz 6. novembra je bila uporabljena redkejša mreža s 1.681 točkami in šestimi jakostmi šuma (600 ocen); starih rezultatov ne smemo brez oznake prenašati na novo konfiguracijo.

7 Implementacija v C++20

7.1 Arhitektura projekta

Razvita je lastna implementacija z uporabo Eigen za matrike in lastni razcep, OpenCV za branje globinskih slik ter standardne knjižnice C++ za generiranje naključnega šuma in delo z datotekami. Python/Matplotlib je uporabljen za prikaz; matematika prileganja ravnine se izvaja v C++.

Tabela 3. Glavne komponente obstoječega projekta.

Datoteka	Vloga
`mapping.hpp`	strukturi `PlaneModel` in `Result`; deklaracije funkcij
`mapping.cpp`	geometrija, šum, PCA, RANSAC, RMSE, Monte Carlo, CSV
`main.cpp`	sintetična scena in primerjava PCA/RANSAC
`depth_to_cloud.cpp`	pretvorba slike D455 v 3D, RANSAC, višinski koordinatni sistem
`scripts/plot.py`	sintetične vizualizacije
`scripts/plot_real.py`	prikazi realnih oblakov, segmentacije in višinske karte
`CMakeLists.txt`	dve izvršljivi poti in ustrezna delovna direktorija

7.2 PCA iz kovariančne matrike

Koda neposredno uresniči enačbe (6)–(13). Uporabljena funkcija `Eigen::SelfAdjointEigenSolver` je namenjena realnim simetričnim matrikam; pri Eigen so lastne vrednosti urejene naraščajoče, zato prvi

stolpec lastnih vektorjev pripada najmanjši lastni vrednosti.

```
Eigen::Vector3d centroid = CalcCentroid(points);
Eigen::Matrix3d C = CalcCovariance(points, centroid);
Eigen::SelfAdjointEigenSolver<Eigen::Matrix3d> solver(C);
plane.normal = solver.eigenvectors().col(0);
plane.d = -plane.normal.dot(centroid);
```

Priporočljivi robni preverjanji sta vsaj tri nekolinearne točke in uspešen lastni razcep. V trenutni implementaciji je preverjeno najmanjše število točk; ločeno preverjanje geometrijske degeneracije je smiselna omejitev za prihodnjo robustnejšo različico.

7.3 RANSAC in končna PCA-ocena

Jedro RANSAC-a je geometrijsko neposredno: razlika točk ustvari smerna vektorja, njun vektorski produkt normalo; po preverjanju praga se izbere največji konsenz, nato pa se model ponovno prilega.

```
Eigen::Vector3d v1 = points[b] - points[a];
Eigen::Vector3d v2 = points[c] - points[a];
Eigen::Vector3d normal = v1.cross(v2);
if (normal.norm() < 1e-10) continue;
normal.normalize();
double d = -normal.dot(points[a]);
// Inlier if abs(normal.dot(points[j]) + d) < threshold
// ... select candidate with largest consensus ...
PlaneModel refined = FitPlanePCA(planePoints);
best.normal = refined.normal;
best.d = refined.d;
```

`PlaneModel` hrani normalo, koeficient d in indekse inlierjev. `RunExperiment()` uporabi `FitPlanePCA()` za posamezno realizacijo šuma; `MonteCarloNoise()` izvaja ponovitve in beleži njihove statistike. S tem je račun PCA napisan samo na enem mestu.

7.4 Računska zahtevnost in ponovljivost

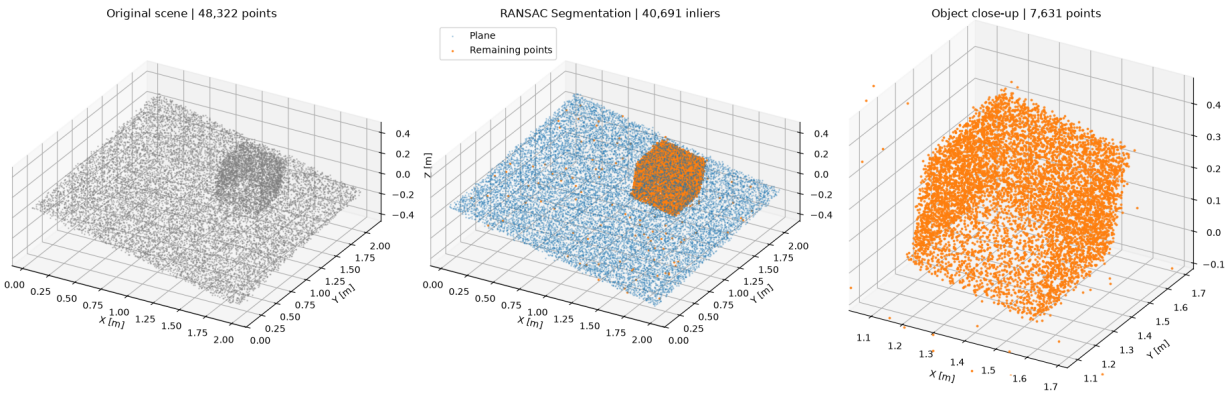
PCA potrebuje en prehod za težišče in enega za kovarianco, oba približno $O(M)$ za M točk; lastni razcep matrike velikosti 3×3 je majhen strošek. RANSAC v osnovni izvedbi preveri vsako točko pri vsakem od K kandidatov, zato prevladuje zahtevnost $O(KM)$. Na 347.474 točkah 50 kandidatov pomeni približno 17 milijonov preverjanj razdalj. Realni eksperiment uporablja generator z izrecnim semenom 42. Sintetični glavni program trenutno uporablja naključno izbrano seme, zato se prikazani rezultati med zagoni nekoliko razlikujejo.

8 Sintetični eksperimentalni rezultati

8.1 Zakaj kocka poslabša globalni PCA

V novo sceno je poleg talne ravnine vključen objekt s 7.921 točkami. V celotnem oblaku je 48.322 točk. Če PCA ocenimo neposredno iz celotne scene, se normalna smer premakne zaradi razpršenosti točk objekta. Na prikazanem konkretnem zagonu je kotna napaka globalnega PCA znašala približno $2{,}69°$, medtem ko je RANSAC s končnim PCA-izboljšanjem dosegel približno $0{,}020°$. To kaže, da ločevanje inlierjev bistveno izboljša orientacijo dominantne ravnine.

RMSE okoli 10 mm je pričakovan ob simuliranem šumu s standardnim odklonom 10 mm; to ne pomeni, da je sama ravnina prostorsko zamaknjena za 10 mm. Segmentacija tudi ni popolna: nekatere točke kocke ob spodnjem robu se lahko zaradi praga 30 mm štejejo med inlierje, nekatere talne točke pa zaradi šuma



Slika 1. Sintetična scena z ravnino 2×2 m in kocko 0,4 m: izvorni oblak, RANSAC-segmentacija ter povečava točk zunaj ravnine. V prikazanem teku je bilo 48.322 točk, približno 40.700 inlierjev in 7.622 preostalih točk. Izvor: prikaz programske vizualizacije, november 2026.

Tabela 4. Primer izpisa sintetičnega poskusa (posamezna naključna realizacija; $\sigma = 10$ mm, $\tau = 30$ mm).

Količina	Izpis
Skupno število točk	48.322
Inlierji dominante ravnine	približno 40.700
Preostale točke	približno 7.622
Kotna napaka globalnega PCA	približno 2,69°
Kotna napaka RANSAC + PCA	približno 0,020°
RMSE končnih inlierjev	približno 10,02 mm

izpadejo.

8.2 PCA pri spreminjajočem se šumu

Monte Carlo eksperiment je ločen od poskusa s kocko: ravnino brez dodatnih objektov rekonstruiramo 100-krat pri vsakem od sedmih σ. V tej fazi preverjamo rast kotne napake, RMSE in napake težišča z močjo šuma; ne ocenjujemo še robustnosti pri osamelcih.

Za sledljivost ohranjamo *prvotni* rezultat iz 6. novembra 2026, ki je temeljil na 1.681 točkah in 600 PCA-ocenah. Ta ni numerično neposredno enak novejšemu gostejšemu preizkusu. Z višanjem σ pov-

Tabela 5. Arhivski referenčni Monte Carlo rezultat: 1.681 točk, 100 ponovitev na σ (6. november 2026).

σ [mm]	$\bar{\theta}$ [°]	s_θ [°]	Povpr. RMSE [mm]	Povpr. e_c [mm]
0	0	0	≈ 0	0
5	0,0145	0,0077	5,003	0,221
10	0,0291	0,0152	9,977	0,389
30	0,0805	0,0434	29,943	1,189
50	0,1535	0,0761	49,867	1,886
100	0,2971	0,1407	99,647	4,080

prečni RMSE sledi velikosti šuma, medtem ko je kotna napaka normale mnogo manjša od razpršenosti posameznih točk. Gosta mreža v trenutni konfiguraciji spremeni stabilnost ocene, zato je za neposredno primerjavo potreben nov izvoz njene preglednice `monte_carlo_noise.csv`.

9 Realni poskus z Intel RealSense D455

9.1 Vhodni podatki in projektivni model kamere

Obravnavani posnetek je 16-bitna globinska slika velikosti 848×480 pikslov. Vsak piksel (u, v) vsebuje celoštevilsko globino $D(u, v)$. Ob pretvorbenem faktorju s je globina v metrih $Z = sD(u, v)$, 3D-točka v koordinatnem sistemu kamere pa

$$\boxed{Z = sD(u,v), \qquad X = \frac{(u - c_x)Z}{f_x}, \qquad Y = \frac{(v - c_y)Z}{f_y}.} \tag{24}$$

To je inverzni perspektivni model brez upoštevanja popačenja slike. Pri kameri velja približno: X desno, Y navzdol, Z od kamere v prizor. Za začetek so uporabljene *približne, ne kalibrirane* vrednosti $f_x = 450$ px, $f_y = 440$ px, $c_x = 424$ px, $c_y = 240$ px ter predpostavljena skala $s = 0{,}001$ m na surovo enoto. Ko bodo na voljo dejanske intrinzične vrednosti in *depth scale*, je treba rekonstrukcijo ponoviti.

Tabela 6. Parametri obdelave izbranega realnega posnetka.

Parameter	Vrednost / opomba
Kamera in vhod	Intel RealSense D455; 16-bitni `depth` PNG
Ločljivost	$848 \times 480 = 407\,040$ pikslov
Intrinzični parametri	$f_x = 450$, $f_y = 440$, $c_x = 424$, $c_y = 240$ px; približki
Globinska skala	$0{,}001$ m / enoto; predpostavka
Globinski filter	$0{,}25 \le Z \le 2{,}0$ m; izloči tudi $D = 0$
RANSAC	50 kandidatov, prag $\tau = 8$ mm, seme generatorja 42

Vhodne globinske slike niso RGB-fotografije. Mape `rgb`, `infrared` in `depth_color` so uporabne za vizualno primerjavo in prihodnje kombiniranje podatkov, vendar je za metrično rekonstrukcijo tukaj uporabljena izključno originalna 16-bitna mapa `depth`. Barvna globinska vizualizacija ne predstavlja neodvisnega vira natančnejših globinskih meritev.

9.2 Od globinske slike do modela ravnine

V C++ preberemo globinsko sliko z `cv::IMREAD_UNCHANGED`, preverimo `CV_16UC1`, odstranimo neveljavne ali izven območja ležeče meritve in za vsak preostali piksel izračunamo (X, Y, Z) po enačbi (24). Dobljeni `std::vector<Eigen::Vector3d>` se shrani v `real_cloud.csv`.

Na tem oblaku funkcija `FitPlanePCA` poda globalno ravnino. Funkcija `RansacPlane` nato poišče dominantno ravnino (50 iteracij, prag 8 mm) in model izboljša s PCA. Indeksi izbranih inlierjev omogočijo ločeno shranjevanje ravninskih in preostalih točk v CSV-datoteke. S tem uporabimo isti lastni geometrijski algoritem kot v sintetičnem poskusu; spremeni se samo izvor vhodnih podatkov.

9.3 Rezultati realnega posnetka

Za prikazani posnetek je program poročal 347.474 sprejetih 3D-točk, 339.796 inlierjev (približno 97,8 %) ter 7.678 preostalih točk. Pri 848×480 pikslov to pomeni, da 59.566 pikslov ni prispevalo točke; vključeni so neveljavni in po potrebi filtrirani globinski piksli. RMSE končnih inlierjev je znašal 2,19895 mm.

Normali se po predznaku razlikujeta, vendar sta skoraj vzporedni. Ker $\boldsymbol{n}$ in $-\boldsymbol{n}$ predstavljata isto neorientirano ravnino, nasprotni predznak ni sam po sebi napaka algoritma. Absolutno kotno napako na realnih podatkih ni mogoče določiti brez neodvisno poznane referenčne normale. Vrednost $|d| \approx 0{,}399$ m predstavlja oddaljenost ravnine od izhodišča kamere *ob sprejetih približnih metričnih parametrih*.

Tabela 7. Rezultat enega realnega posnetka D455 (izpis 13. november 2026).

Količina	Rezultat
Veljavne 3D-točke	347.474
RANSAC inlierji	339.796 (97,8 %)
Preostale točke	7.678 (2,2 %)
RMSE ravnine na inlierjih	2,19895 mm
Globalna PCA normala	$(0{,}113337,\ 0{,}053875,\ -0{,}992095)$
RANSAC + PCA normala	$(-0{,}113180,\ -0{,}051391,\ 0{,}992245)$
Koeficient d izbrane ravnine	$-0{,}399392$ m

9.4 Transformacija v koordinatni sistem ravnine

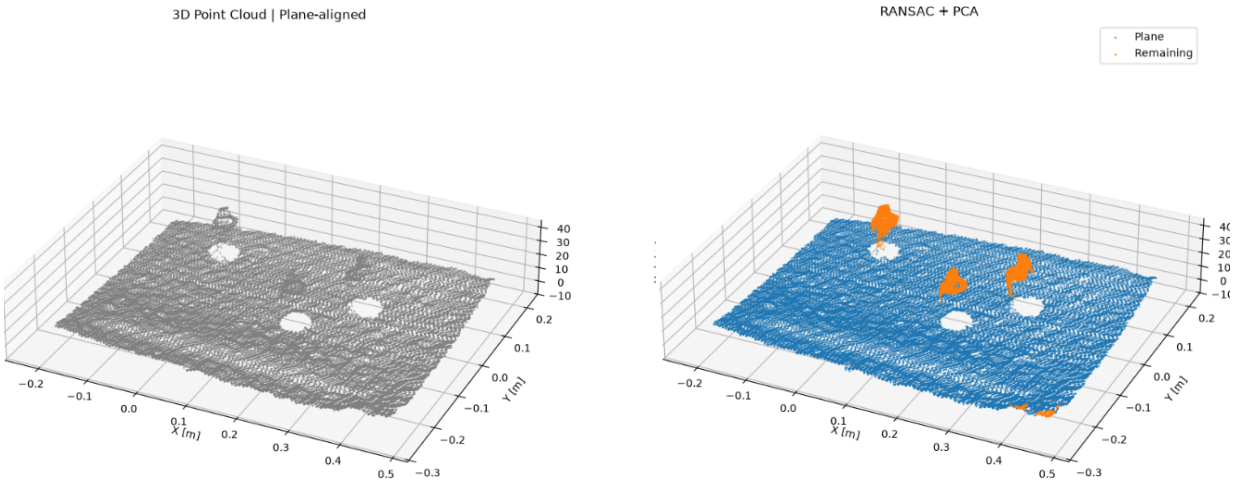
Neposredni prikaz 3D-točk kamere je lahko vizualno zavajajoč: pri globinski kameri je os Z globina, ne navpična višina nad ploščo. Zato iz ocene ravnine sestavimo novo ortonormirano bazo. Naj bo $\boldsymbol{n}$ njena normala, usmerjena približno proti kameri (v tem posnetku z negativno komponento n_z). Kot novo izhodišče izberemo točko na ravnini, ki je najbližja izhodišču kamere:

$$\boldsymbol{p}_0 = -d\boldsymbol{n}_{\text{fit}}, \qquad \boldsymbol{e}_x = \frac{\boldsymbol{a} - (\boldsymbol{a}^T\boldsymbol{n})\boldsymbol{n}}{\|\boldsymbol{a} - (\boldsymbol{a}^T\boldsymbol{n})\boldsymbol{n}\|}, \quad \boldsymbol{e}_y = \boldsymbol{n} \times \boldsymbol{e}_x, \tag{25}$$

pri čemer je $\boldsymbol{a} = (1, 0, 0)^T$ in $\boldsymbol{n}_{\text{fit}}$ normala iz izvornega modela z njegovim koeficientom d. Nato za vsako meritev izračunamo

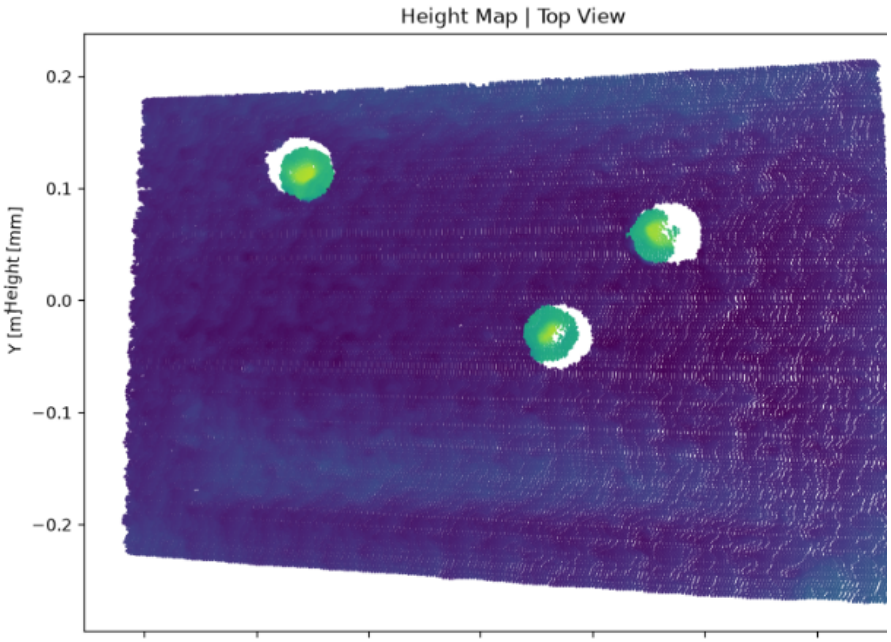
$$\boxed{\begin{bmatrix} x' \\ y' \\ h \end{bmatrix} = \begin{bmatrix} \boldsymbol{e}_x^T \\ \boldsymbol{e}_y^T \\ \boldsymbol{n}^T \end{bmatrix} (\boldsymbol{p} - \boldsymbol{p}_0).} \tag{26}$$

Tu sta x' in y' koordinati po površini plošče, h pa *predznačena višina nad ploščo*. To je toga sprememba koordinatnega sistema, ne zgolj preimenovanje osi Z. Ravnina je zato približno $h = 0$, veljavne meritve predmetov, ki štrlijo proti kameri, pa imajo praviloma $h > 0$.



(a) Oblak poravnan z ravnino. **(b)** RANSAC-inlierji in ostale točke.

Slika 2. Obdelava realnih podatkov D455: po rotaciji v koordinatni sistem plošče je lažje razlikovati ravnino od povišanih meritev. Prikaz je programska vizualizacija, ne rekonstrukcija skritih površin.



Slika 3. Višinska karta realnega oblaka. Trije lokalni skupki višjih izmerjenih točk so jasno vidni; belina ob njih kaže območja brez prikazanih veljavnih globinskih meritev. Barvna lestvica pri prikazu je namenoma omejena na okvirno območje od -5 do 40 mm, zato sama po sebi ne daje največje izmerjene višine.

9.5 Interpretacija, omejitve in česa rezultat še ne pomeni

Višinska karta pokaže približno ravninsko podlago in tri območja višjih meritev. RANSAC zato uspešno loči veliko večino podlage od povišanih točk. Vendar bela območja okrog predmetov ostajajo, ker za nekatere piksle ni veljavne globinske meritve. Niti PCA niti RANSAC ne moreta iz nič rekonstruirati manjkajoče geometrije. Metoda *ne* poda popolne površine predmeta, njegove absolutne metrične višine brez preverjene skale ali njegove semantične oznake (oranžen, črn, bel).

RMSE približno 2,20 mm meri *razpršenost izbranih inlierjev okoli ocenjene ravnine*. Ne pomeni, da ima D455 absolutno globinsko napako samo 2,20 mm, in ni zagotovilo metrične točnosti brez kalibracije. Zelo velik delež inlierjev je v tem primeru pričakovan, ker večino veljavnih pikslov predstavlja plošča. Na drugih posnetkih, kjer dominira druga površina ali je plošča delno zakrita, lahko RANSAC izbere drugačno dominantno ravnino.

10 Razprava, preverljivost in sklepi

10.1 Kaj je bilo doseženo

Matematična PCA-izpeljava pokaže, da je smer najmanjše variance normalni vektor ravnine, ki minimizira pravokotne kvadratne odmike. RANSAC doda robustno iskanje konsenzne množice, zato je kombinacija RANSAC + PCA primernejša za večstrukturirane prizore kot globalni PCA sam. Sintetična scena to pokaže neposredno: v enem izmed dokumentiranih tekov se kotna napaka zmanjša z okoli $2{,}69^\circ$ na okoli $0{,}020^\circ$.

Realni preizkus poveže izvorno globinsko sliko D455, projekcijo v 3D in *isto lastno implementacijo* ocene ravnine. Dobljeni rezultati vsebujejo ločitev ravnine od drugih meritev in koordinatno poravnano višinsko karto. To je funkcionalen sklop za geometrijsko obdelavo enega RGB-D zajema; ne gre še za

večpogledno rekonstrukcijo, lokalizacijo ali SLAM.

10.2 Kako ponovimo preizkusa

CMake cilj `plot` požene sintetični program in vizualizacijo; cilj `real_cloud` obdela v CMake podano globinsko sliko. Če po generiranju CSV želimo posebej prikazati realno sceno, neposredno zaženemo Pythonovo skripto. Tipičen zagon iz korena projekta je:

```
cmake -S src/mapping_framework -B build
cmake --build build --target plot
cmake --build build --target real_cloud
.venv/bin/python scripts/plot_real.py
```

Pred izvajanjem je treba namestiti Eigen3, OpenCV, ustrezen C++20 prevajalnik in Pythonova paketa NumPy ter Matplotlib. Ker so vhodne poti določene v CMake, morajo v projektu obstajati tudi ustrezni izvorni globinski posnetki. Če se struktura imenika `data/generated` spremeni, morata biti lokaciji izhodnih CSV in vhodov Pythonovih skript medsebojno usklajeni. Reproducibilnost sintetičnega rezultata zahteva fiksno seme namesto trenutno naključno izbranega začetnega semena.

10.3 Odprte omejitve

Pred nadaljnjo metrično analizo so pomembni: dejanski intrinzični parametri in skala D455, dodatna ocena kakovosti globinskih meritev, preverjanje praga RANSAC na več prizorih in testiranje degeneriranih vzorcev. Segmentacija po enem pragu loči dominantno ravnino od ostalega oblaka, vendar sama po sebi še ne razdeli več objektov na samostojne skupine. Pri prihodnjem združevanju več oblakov bodo potrebne tudi poze zajemov in transformacije koordinatnih sistemov.

10.4 Sklep

Razvito programsko ogrodje uspešno prenese matematični metodi PCA in RANSAC iz nadzorovanega sintetičnega testa na realne globinske podatke D455. Glavni prispevek trenutne faze ni nova teorija SLAM-a, temveč *transparentna, preverljiva in ponovno uporabna implementacija* generiranja in obdelave 3D-točk, robustnega prileganja ravnin ter višinske predstavitve okolice. Delo s tem predstavlja konsistentno podlago za nadaljnje robotsko 3D-kartiranje.

Literatura

[1] I. T. Jolliffe, *Principal Component Analysis*, 2. izd., Springer, 2002.

[2] G. H. Golub in C. F. Van Loan, *Matrix Computations*, 4. izd., Johns Hopkins University Press, 2013.

[3] M. A. Fischler in R. C. Bolles, “Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography,” *Communications of the ACM*, 24(6), 381–395, 1981.

[4] Eigen Project, *Eigen C++ Template Library*, dokumentacija knjižnice (matrike in reševalniki lastnih vrednosti).

[5] OpenCV, *Open Source Computer Vision Library*, dokumentacija `imread` in predstavitve slikovnih tipov.